

Laporan Teknis DompertCerdas AI

Data Science Pipeline - Capstone Project

Tim: CC26-PSU115

Tanggal: Juni 2026

Versi: 2.0

Daftar Isi

1. Problem Discovery
 2. Pertanyaan Bisnis
 3. Data Gathering
 4. Data Assessing
 5. Data Cleaning
 6. Exploratory Data Analysis (EDA)
 7. Explanatory Analysis
 8. Outlier Handling
 9. Feature Engineering
 10. Data Splitting & Export
 11. A/B Testing
 12. Data Dictionary
 13. Dashboard Streamlit
 14. Kesimpulan & Rekomendasi
-

1. Problem Discovery

Latar Belakang

Pengelolaan keuangan pribadi merupakan tantangan besar bagi masyarakat Indonesia, terutama generasi muda. Banyak individu yang kesulitan mengelola pengeluaran, membuat budget yang realistis, dan mengidentifikasi pola pengeluaran yang tidak sehat.

Solusi Utama

DompertCerdas AI — aplikasi manajemen keuangan pintar berbasis AI yang membantu user:

- Melacak transaksi secara otomatis
- Menganalisis pola pengeluaran
- Mendeteksi anomali/transaksi mencurigakan
- Memprediksi health score keuangan
- Memberikan rekomendasi budget yang dipersonalisasi

Ruang Lingkup Data Science

Data Science bertanggung jawab untuk:

- 1. Membangun dataset sintetis yang realistis
- 2. Melakukan analisis data end-to-end
- 3. Menyiapkan data untuk model ML (AI Engineer)
- 4. Membangun dashboard interaktif
- 5. Memberikan insight bisnis dari data

2. Pertanyaan Bisnis

7 pertanyaan bisnis yang terukur:

#	Pertanyaan	Metrik
Q1	Kategori pengeluaran mana yang memiliki proporsi tertinggi di setiap segmen user?	Total spending per kategori per segmen
Q2	Bagaimana perbandingan rata-rata pengeluaran weekday vs weekend pada hiburan & makanan?	Rata-rata amount per tipe hari
Q3	Metode pembayaran dominan untuk transaksi < Rp 100.000 pada pekerja tetap?	Proporsi payment method
Q4	Apakah ada perbedaan rata-rata pengeluaran antara user yang punya hutang vs tidak?	Rata-rata amount per debt status
Q5	Apakah ada user yang pengeluaran bulannya melebihi income?	Proporsi overbudget vs aman
Q6	Apakah user dengan pemasukan non-gaji memiliki saving ratio lebih tinggi?	Saving ratio per income type
Q7	Segmen user mana yang memiliki rata-rata surplus bulanan tertinggi?	Surplus per segmen

3. Data Gathering

Sumber Data

Dataset sintetis yang di-generate untuk simulasi ekosistem DompetCerdas AI:

Dataset	Baris	Kolom	Deskripsi
synthetic_users.csv	175	14	Profil pengguna (3 segmen, income, savings, debt)
synthetic_transactions_raw.csv	110,320 +	11	Transaksi harian (12 bulan)
synthetic_budgets.csv	~2,000	6	Alokasi budget per user/bulan/kategori

Segmen User

Segmen	Jumlah	Karakteristik
pelajar_mahasiswa	~58	Income rendah, pengeluaran dasar
pekerja_tetap	~57	Income stabil, kewajiban rutin
freelancer	~57	Income variatif, fleksibel

Special Users

- **user_0001:** Empty profile (demo)
 - **user_0002:** Limited data (demo)
 - **user_0003:** Ready profile (demo)
 - **user_0004-0175:** Regular users
-

4. Data Assessing

Temuan Utama

Aspek	Status	Detail
Missing Values	✓ Minimal	Hanya kolom <code>merchant</code> yang memiliki NaN
Duplikat	✓ Sedikit/ Tidak ada	Dataset sintetis sudah bersih
Tipe Data	⚠ Perlu Konversi	<code>transaction_date</code> string → datetime, <code>is_synthetic_anomaly</code> string → boolean
Kategori	✓ Bersih	Lowercase, konsisten, tanpa typo
Outlier	⚠ Ada	Transaksi anomali ditandai <code>is_synthetic_anomaly=true</code>

Statistik Deskriptif

- **Amount range:** Rp 1.000 - Rp 15.000.000 +
 - **Mean amount (pengeluaran):** Rp 94.866
 - **Std dev:** Rp 153.153
 - **Kategori:** 12 (9 expense + 3 income)
 - **Payment methods:** 5 (cash, e-wallet, debit, credit_card, bank_transfer)
-

5. Data Cleaning

Proses Cleaning

1. **Drop Duplicates:** Menghapus baris duplikat (jika ada)
2. **Convert `transaction_date`:** String → datetime64
3. **Convert `is_synthetic_anomaly`:** String 'true'/'false' → boolean
4. **Fill Missing `merchant`:** NaN → 'Unknown'
5. **Extract Date Features:** year, month, day_of_week, is_weekend
6. **Merge User Info:** Gabung `user_segment`, `monthly_income`, `has_savings`, `has_debt`

Hasil

- **Total baris setelah cleaning:** 110,320 rows
 - **Missing values setelah cleaning:** 0
 - **Kolom tambahan:** 4 fitur temporal
-

6. Exploratory Data Analysis (EDA)

EDA 1: Distribusi Pengeluaran per Kategori (Boxplot)

[image]

Insight: Kategori `kos_sewa` dan `kesehatan` memiliki nilai per transaksi tertinggi. Makanan dan transportasi memiliki frekuensi tinggi dengan nilai per transaksi yang lebih kecil.

EDA 2: Frekuensi Transaksi per Kategori

[image]

Insight: Makanan dan transportasi mendominasi frekuensi transaksi karena merupakan kebutuhan harian.

EDA 3: Tren Pengeluaran Bulanan

[image]

Insight: Pola pengeluaran bulanan menunjukkan seasonal pattern yang jelas dengan variasi antar bulan.

EDA 4: Proporsi Pengeluaran

[image]

Insight: Kategori dengan proporsi nominal terbesar perlu menjadi perhatian dalam budget planning.

EDA 5: Heatmap & Weekday vs Weekend

[image]

Insight: Heatmap menunjukkan konsentrasi pengeluaran per kategori per bulan. Total spending weekday lebih tinggi karena lebih banyak hari kerja.

EDA 6: Rata-rata per Transaksi (Weekday vs Weekend)

[image]

Insight: Rata-rata nominal per transaksi relatif stabil antara weekday dan weekend.

EDA 7: Distribusi User Segment

[image]

Insight: Distribusi user seimbang antar segmen. Freelancer memiliki income paling tinggi dan variatif.

7. Explanatory Analysis

Q1: Top Kategori per Segmen

Setiap segmen memiliki pola pengeluaran berbeda:

- **Pelajar:** Makanan & transportasi mendominasi
- **Pekerja Tetap:** Kos_sewa & tagihan mendominasi
- **Freelancer:** Pengeluaran lebih tersebar merata

Q2: Weekday vs Weekend (Hiburan & Makanan)

Rata-rata pengeluaran makanan dan hiburan sedikit lebih tinggi di weekend, tapi perbedaan tidak signifikan.

Q3: Payment Method Dominan (< Rp 100.000)

E-wallet dan cash adalah metode pembayaran paling dominan untuk transaksi mikro.

Q4: Hutang vs Tidak

User dengan hutang memiliki rata-rata pengeluaran yang berbeda, menunjukkan perlunya rekomendasi yang dipersonalisasi.

Q5: Overbudget Analysis

Proporsi user yang overbudget vs terkendali menunjukkan besarnya masalah finansial.

Q6: Saving Ratio (Gaji vs Non-Gaji)

User dengan pendapatan tambahan (freelance, bonus) memiliki saving ratio yang berbeda.

Q7: Surplus per Segmen

Freelancer biasanya memiliki surplus tertinggi. Pelajar paling rendah.

8. Outlier Handling

Strategi: Percentile Capping (1%-99%)

ATURAN KRUSIAL: Capping HANYA pada data normal (`is_anomaly == False`). Data anomali dipertahankan utuh untuk model anomaly detection.

Thresholds per Kategori

Setiap kategori memiliki threshold P01 dan P99 berbeda sesuai karakteristiknya. Capping menekan noise tanpa merusak distribusi utama.

9. Feature Engineering

Fitur Turunan

Fitur	Formula	Tujuan
spending_ratio	amount / monthly_income	Konteks personal ke model
is_large_transaction	1 jika amount > 50% income	Sinyal potensi anomali
days_since_salary quarter	Hari sejak tanggal 25 Kuartal (1-4)	Pola payday splurge Seasonal pattern
cat_makanan ... cat_pendidikan	Binary (0/1)	One-hot encoding kategori
segment_encoded	LabelEncoder	Segment → integer
category_encoded	LabelEncoder	Kategori → integer
tx_type_encoded	LabelEncoder	Tipe transaksi → integer
payment_encoded	LabelEncoder	Payment → integer

Anti Data Leakage

- Semua fitur dihitung dari variabel yang tersedia saat transaksi terjadi
 - **Scaler** di-fit HANYA dari train set
 - **Chronological Split**: Train sebelum cutoff, test sesudah cutoff
-

10. Data Splitting & Export

Data Splitting

Split	Rows	Range
Train	88,178 (79.9%)	Juni 2025 - Maret 2026
Test	22,142 (20.1%)	Maret 2026 - Mei 2026

Artifacts Exported

File	Rows	Tujuan
03_clean_final.csv	110,320	Dataset utama
05_train.csv	88,178	Train chronological
05_test.csv	22,142	Test chronological
04_monthly_aggregated.csv	1,930	Per user/month agregat
04_category_pivot.csv	1,930	Per user/month/category pivot
scaler.pkl	-	MinMaxScaler (train-fitted)
category_label_mapping.json	12 mapping	Kategori → integer
segment_label_mapping.json	3 mapping	Segment → integer

payment_label_mapping.json 5 mapping Payment → integer
data_dictionary.csv 36 kolom Dokumentasi lengkap

11. A/B Testing

Metodologi

Simulasi untuk mengukur efektivitas AI recommendation:

- **Grup A (Kontrol):** Spending aktual (tanpa AI)
- **Grup B (Treatment):** $\text{Spending} \times (1 - \text{random_savings_rate}[10-15\%])$

Hipotesis

- **H0:** Tidak ada perbedaan signifikan antara spending dengan/tanpa AI
- **H1:** Spending dengan AI recommendation lebih rendah secara signifikan

Hasil

[image]

Metrik	Nilai
Grup A mean	Rp 94.866
Grup B mean	Rp 83.005
Rata-rata pengurangan	12.5%
t-statistic	19.0188
p-value	0.0000000000

Kesimpulan

✓ **H0 ditolak** ($p < 0.05$). AI recommendation efektif mengurangi spending rata-rata 12.5%. Ini menjadi dasar proof of concept untuk pengembangan AI Budget Planner.

12. Data Dictionary

Dokumentasi lengkap 36 kolom tersimpan di `data/data_dictionary.csv` dengan kolom:

- `column_name`: Nama kolom
 - `data_type`: Tipe data
 - `description`: Deskripsi bahasa Indonesia
 - `example_value`: Contoh nilai
-

13. Dashboard Streamlit

Dashboard interaktif 8 halaman:

1. **Overview:** Ringkasan dataset & statistik
2. **EDA:** 7 visualisasi eksplorasi
3. **Explanatory:** Jawaban 7 pertanyaan bisnis
4. **User Analysis:** Analisis per user individual
5. **Segment Analysis:** Perbandingan segmen
6. **Financial Health:** Status keuangan & overbudget
7. **A/B Testing:** Hasil simulasi
8. **Data Dictionary:** Dokumentasi kolom

File: streamlit_app.py

14. Kesimpulan & Rekomendasi

Insight Utama

1. **Kebutuhan Primer Mendominasi:** Makanan dan transportasi adalah pengeluaran paling sering
2. **Potensi Overbudget:** Sebagian besar user menghabiskan lebih dari income bulanan
3. **AI Budget Planner Layak Dikembangkan:** A/B testing menunjukkan penghematan 12.5% signifikan
4. **Segmentasi Penting:** Setiap segmen user memiliki pola pengeluaran berbeda

Rekomendasi untuk AI Engineer

1. Model anomaly detection harus memanfaatkan data `is_anomaly` yang sudah disiapkan
2. Model prediksi health score menggunakan `04_monthly_aggregated.csv`
3. Model LSTM sequential menggunakan `04_category_pivot.csv`
4. Scaler dan label mapping tersedia di folder `data/`

Anti Data Leakage Compliance

- ✓ Scaler di-fit hanya dari train set
 - ✓ Chronological split (bukan random)
 - ✓ Anomali TIDAK di-capping
 - ✓ Target `is_anomaly` tidak termasuk dalam fitur training
 - ✓ Semua fitur dihitung dari variabel yang tersedia saat transaksi
-

Laporan ini di-generate otomatis dari pipeline `DompCerdasAI_DataPipeline.ipynb`